Программирование на Ruby для лингвистов a.k.a. Ruby for Smart Linguists

Basic Ruby (w/o classes)

About

- Создатель: Yukihiro Matsumoto (matz)
- Первая версия в 1995
- Применяется в

  консольные инструменты, *прототипирование*

  GUI (есть библиотеки tk)

  веб программирование Ruby on Rails

Версии Ruby

- прекращена поддержка версии 1.8.7
- текущие версии 1.9.x и 2.0.0

  ruby-1.9.2-p290
  ruby-1.9.3-p448
  ruby-1.9.3-rc1
  ruby-2.0.0-p247

- реализации Ruby

ruby :: MRI/YARV Ruby (The Gold Standard) {1.8.6,1.8.7,1.9.1,1.9.2...}
jruby :: JRuby, Ruby interpreter on the Java Virtual Machine.
rbx :: Rubinius
ree :: Ruby Enterprise Edition, MRI Ruby with several custom patches for performance, stability, and memory.
macruby :: MacRuby, insanely fast, can make real apps (Mac OS X Only).
maglev :: GemStone Ruby, awesome persistent ruby object store.

Осторожно, несовместимость!

- несовместимость между

  ruby 1.8.7
  ruby 1.9.x (1.9.2, 1.9.3)

good news!
ruby 1.9.x = 2.0.0

- ruby 1.8.7

```
"hello"[0]    #=> 104
```

- ruby 1.9.x и 2.0.x

```
"hello"[0]    #=> “h”
```

Совет!

решаясь перейти на
новую версию,
читать **ChangeLog**

Полезные утилиты - irb

- irb – интерактивный Ruby, консоль Ruby

```
> irb
```

REPL - read, evaluate, print, loop

- Запустите irb и попробуйте выполнить следующие команды

```
3+6          #=> 9
9/4          #=> 2
9.0/4        #=> 2.25
9.to_f/4     #=> 2.25
```

метод to_f преобразует во float
(число с плавающей точкой)

```
puts “hello ” + “world”
```

оператор puts
put string

```
num = 5
puts num
```

набрать quit

Задание

Задание: в irb, создайте переменную, содержащую строку “hello world”

> str = “hello world”

выделите из строки первую букву каждого из слов, объедините и распечатайте. Должно получится “hw”

Решение:

```
str = “hello world”

puts str[0] + str[6]
```

Полезные утилиты - ri

- ri – (ruby information) консольная справочная система Ruby

```
> ri --help
> ri --list
> ri
```

- Выполните команды

```
> ri String
> ri String#downcase
```

Метод downcase объекта (экземпляра) класса String

пример использования **метода объекта**: “Hello”.downcase

```
> ri String.new
> ri String.downcase
```

Метод new класса String

пример использование **метода класса**: str = String.new

Задания

- Задание: запустите irb и в нем выполните преобразование сроки к верхнему регистру. Какой **метод** надо применить к строке? Вставьте его вместо xxx:

```
puts “hello”.xxx
```

```
ri String#upcase
```

- многоликий puts. этот метод определен во многих классах

```
> ri puts
```

- Задание: исследуйте отличия puts от print

```
puts "hello"; puts "world"
```

```
$, = “;”
```

```
print "hello"; print "world"
```

```
print "hello", "world"
```

Переменные vs. Константы

- Переменные (изменяемые) vs константы (неизменяемые)
- Правила именования переменных и констант
  - буквы [A-Za-z]
  - цифры (не может быть первой) [0-9]
  - нижнее подчеркивание _

```
name_1 = “Ruby”
```

- Переменная не должна начинаться с большой буквы.
- Вопрос: с чего может начинаться имя переменной?

  Ответ: _[a-z]

Переменные vs. Константы

- Константы начинаются с большой буквы.

lesson.02/test_stderr.rb

```
STDOUT.puts
STDERR.puts
```

- попробуйте в irb

```
> puts RUBY_VERSION
```

#=>1.9.2

- Задание: создайте свою константу

```
> ZZZ = 123
> Qqq = 666
```

и присвойте им другое значение

```
> ZZZ = “reassigned”
> Qqq += 2
```

```
(irb):6: warning: already initialized
constant  ZZZ
=> "reassigned"
```

Константы

- Константами считаются имена классов и модулей
  - String, Array, Hash
  - Enumerable, Comparable
  - MyOwnClass, Myownclass, My_own_class
- Убедитесь в этом, выполнив команду

```
> ri --classes
```

- Вопрос: Чем являются _var и _Var, переменными или константами?

```
_var = 9
_Var = 99
```

Типы данных

- Любой программный объект принадлежит к тому или иному типу
- Тип определяет
  - допустимые значения и свойства
  - перечень операций, применимых к значениям данного типа
- Некоторые типы данных
  - численные: Integer, Float, Fixnum (<Integer), Bignum (<Integer), Numeric
  - строковые String
  - логические (булевские = boolean): FalseClass, TrueClass
  - File, IO
  - Symbol
  - Array, Hash

Типы данных - 2

- Язык Ruby позволяет задавать свои собственные типы (определять классы) и снабжать их необходимыми свойствами.
  - Dictionary
  - PartOfSpeechDictionary
  - Sentence
  - Word
  - AnnotatedWord

Типы данных - 3

- Языки делятся на языки с
  - динамической типизацией (shell, awk, ruby, python,...)
  - статической типизацией (C, Java)
- При статической типизации
  - тип переменной задается сразу

    int a = 20
  - тип переменной нельзя изменить в процессе работы

    a = “now this is a string”
- Ruby – язык с динамической типизацией

А в руби?

Аллилуйа!

Пример

- Выполните скрипт lesson.02/script_2.rb

lesson.02/script_2.rb

```
#!/usr/bin/env ruby

a = 10
puts a, a.class

a = “ten”
puts a, a.class

a = “10”
puts a, a.class
```

метод class позволяет
узнать тип объекта

Задание

- Задание: выясните, к какому типу принадлежат следующие значения

3.14	3.14.class #=> Float
“3.14”	“3.14”.class #=> String, потому что в кавычках
[1, 2, 3]	[1, 2, 3].class #=> Array, потому что в квадр. скобках
:Array	:Array.class #=> Symbol, потому что начинается с :
1..5	(1..5).class #=> Range, потому что START..END
/[a-z]/	/[a-z]/.class #=> Regexp, потому что в слэшах

Задание

- Какой результат выполнения следующих операций?

20 + 30	#=> 50
“20” + “30”	#=> “2030” конкатенация строк
20 * 3	#=> 60 арифметическое умножение
“20” * 3	#=> “202020” String multiplication
“20” * “3”	#=> TypeError: can't convert String into Integer

Присваивание (assignment)

- Оператор = служит для присвоения значения переменной

```
num = 42
```

- Параллельное присваивание

```
word, freq, tag = “apple”, 42, “noun”
word, freq, tag = “apple”, 42, “noun”
```

```
word = “apple”
freq = 42
tag = “noun”
```

- пример:

```
word, tag = "apple_NN".split(/_/)
```

- Исследуйте, какие значения примут переменные:

```
a,b,c = 10,20
```

```
a,b,c = 10,20,30,40
```

Задание

• Задание: задайте две переменные (значение одной “Susan” а другой 25) и выведите текст

“her name is Susan and she is 25 years old”

Подсказка: в скрипте использовать оператор конкатенации строк +

```
#!/usr/bin/env ruby

 name, age = “Susan”, 25

puts “her name is ” + name + “ and she is ” + age + “ years old”

puts “her name is #{name} and she is #{age} years old”
```

#{...} интерполяция

Задание

- Решение 2: преобразование типов (привести к типу String)

```
#!/usr/bin/env ruby

name, age = “Susan”, 25

puts “her name is ” + name + “ and she is ” + age.to_s + “ years old”
```

```
age.class
```

#=> Fixnum

```
ri Fixnum#to_s
```

см. lesson.03/interpolation/test_puts.1.rb

Рюшечки: puts с шаблоном

- шаблон и позиционная подстановка

```
#!/usr/bin/env ruby

name, age = “Susan”, 25
template = “her name is %s and she is %s years old”

puts template % [ name, age ]
```

см. также судоку

```
> ruby sudoku_solver.rb
```

Оператор условия if

- if / then / end

```
if EXPRESSION [; then]
   # если EXPRESSION истинно,
   # то попадаем в эту ветку
    ...
end
```

; перед *then* необязательно

```
a = 5

if a > 0
    puts “#{a} is a positive number”
end

if a > 0; then
    puts “#{a} is a positive number”
end
```

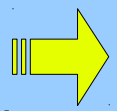

это true

может употребляться в постпозиции:

```
puts “#{a} is a positive number”  if a > 0
```

Оператор условия if

- if / then / end

```
if EXPRESSION [; then]
   # если EXPRESSION истинно,
   # то попадаем в эту ветку
    ...
end
```

; перед *then* необязательно

```
a = 5

if a > 0
    puts “#{a} is a positive number”
end

if a > 0; then
    puts “#{a} is a positive number”
end
```

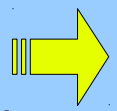

это true

может употребляться в постпозиции:

```
puts “#{a} is a positive number”  if a > 0
```

if пошагово

```
a, b = 10, 10

if a > 0 && a == b
   puts “hello”
end
```

```
a, b = 10, 10

if true && a == b
   puts “hello”
end
```

проверка
на равенство
==

```
a, b = 10, 10

if true && true
   puts “hello”
end
```

```
a, b = 10, 10

if true
   puts “hello”
end
```

```
a, b = 10, 10


puts “hello”
```

“hello”

Оператор условия if

- if / then / else / end

```
if EXPRESSION [;then]
    # сюда если TRUE
else
    # сюда если FALSE
end
```

; перед *then* необязательно

```
a = - 5

if a > 0
    puts “#{a} is a positive number”
else
    puts “#{a} is not a positive number”
end
```

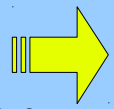

это false

Задание

- чему равны **a** и **b** после выполнения данного кода?

проверка
на НЕравенство
!=

```
a, b = 10, 10

if a > 0 && a != b
   b = b - 1
else
   b = b + 1
end
```

```
a, b = 10, 10

if true && a != b
   b = b - 1
else
   b = b + 1
end
```

```
a, b = 10, 10

if true && false
   b = b - 1
else
   b = b + 1
end
```

```
a, b = 10, 10

if false
   b = b - 1
else
   b = b + 1
end
```

```
a, b = 10, 10

if false
   b = b - 1
else
   b = b + 1
end
```

```
a, b = 10, 10

if false
   b = b - 1
else
   b = 11
end
```

Оператор условия if

- if / then / elsif+ / else / end

; перед *then* необязательно

```
if EXPRESSION1 [; then]
    …
elsif EXPRESSION2 [; then]
    …
elsif EXPRESSION3 [; then]
    ...
else
    ...
end
```

ветка else необязательна

- если EXPRESSION1 равен TRUE, то дальнейшие условия не проверяются

Сопоставление РВ

- Условные операторы, сопоставляющие (matching) строки:

оператор	описание	операнды	ыднарепо
=~	метчит	string =~ regexp	regexp =~ string
!~	не метчит	string !~ regexp	regexp !~ string

Например:

“paper” =~ /[a-z]/

/[0-9]/ =~ “paper”

```
str = “paper”

if str !~ /[a-z]/
    puts “no letters”
else
    puts “contains letters”
end
```

Сопоставление РВ

- Что возвращают следующие команды (в irb)?

“paper” =~ /[a-z]/ #=> 0

“Paper” =~ /[a-z]/ #=> 1

“Paper” =~ /[0-9]/ #=> nil

ri String#=~

возвращается позиция начала метча -
позиция первого символа,
который заметчило регулярное выражение
(отсчет позиций с 0)

"paper" !~ /[0-9]/ #=> true

Что есть true и что есть false

- ***Любое*** выражение или объект в руби имеет булевское (логическое) значение (true или false)

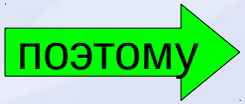

любое выражение или объект можно использовать в условных конструкциях

```
if  “Paper” =~ /[a-z]/
   …
end
```

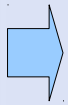

```
if 1
   …
end
```

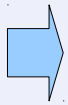

```
if true
   …
end
```

- Вопрос: что произойдет в результате выполнения следующей команды?

```
if 1; then puts “is true”; else puts “is false”; end
```

Задания

- Выясните, какие из следующих значений считаются true в руби?

-5	true	
0	true	в AWK false
“paper”	true	
“”	true	в AWK false
true	true	отсутствует в AWK
false	false	отсутствует в AWK
nil	false	отсутствует в AWK

Циклы

- Циклы позволяют выполнить какое-то действие/действия **несколько раз**.
- Сравните, сколько раз выполнится блок (lesson.03/while/test_while_1.rb)

a = 2
if a < 5
  b = a ** 2
  print b
end
	a = 2
	while a < 5
	  b = a ** 2
	  print b, ", "
	  a += 1
	end

#=>4	#=> 4, 9, 16

• Способы организации циклов в руби:

while (until), for, loop, times, upto, downto, step, each и его братья

• Другие операторы, управляющие циклами:

next, break; *retry*, *redo*

Цикл while

- Цикл while выполняется, пока условие истинно

```
while expression-that-is-TRUE [do]
  # ....
end
```

- Сколько раз выполниться следующий цикл (while/test_while_2.rb)? Расскажите, как он выполняется:

```
i = j = 0

while i < 5 && j < 5
  puts "i=#{i}, j=#{j}"
  i += 1
  j += i
end

puts ""
```

i=0, j=0
i=1, j=1
i=2, j=3

Почему цикл не пошел на следующую итерацию?

i=3, j=6

Цикл while с IO#gets

- Вопрос: объясните, как работает следующий цикл?

  например, обрабатывается файл, в котором одна строка "hello"

```
while line = gets
  # действия
  # line.chomp!
  ...
end
```

```
while line = "hello"
  #  ...
end
```

```
while "hello"
  #  ...
end
```

```
while true
  #  ...
end
```

- Вопрос: В какой момент этот цикл остановится? читать: IO#gets

  Ответ: из IO#gets: Returns +nil+ if called at end of file.

- Принудительное завершение цикла: break

```
while true; do
  …
  break  if some-condition
  ...
end
```

Чтение из потока ввода

```
ri IO#gets
```

- выполните скрипт lesson.03/gets/test_gets.1.rb

- Прочитайте скрипт и скажите, то ли выводится, что “хотел” сказать программист.

  для сравнения, выполните lesson.03/gets/test_gets.2.rb

- Исправьте скрипт test_gets.1.rb, чтобы он работал аналогично test_gets.2.rb

```
ri String#chomp
ri String#chop
ri String#strip
```

```
ri String#chomp!
ri String#chop!
ri String#strip!
```

Задания

- Задание: напишите скрипт (test_numbers.rb), который просит пользователя ввести целое число и сообщает об этом числе, является ли оно положительным, отрицательным или нулем

test_numbers.rb

```
#!/usr/bin/env ruby

msg = "Enter an integer number"
puts msg

while num = gets
    num = num.chomp.to_i

    # TODO: write your code here that tests the number
    if num …

    puts msg
end
```

Ответ: lesson.03/test_numbers_done.rb

Задание

- Задание: Будет ли работать следующий скрипт?

```
#!/user/bin/ruby

while line = gets
    line.chomp!

    if line == “quit”
       exit
    elseif line < 0
       puts line + “ is a negative number”
    else if line == “0”
       puts line + “ is zero”
    elsif
       puts “#{line} is a negative number”


end
```

Задание

- Задание: исправьте скрипт lesson.03/test_numbers_buggy.rb

  в коментариях описано, что он должен делать

  см. ответ в lesson.03/test_numbers_correct.rb

Задание

- на материале файла data/words.txt, подсчитайте скриптом, сколько
  - в файле строк
  - сколько слов, начинающихся с большой буквы
  - сколько слов, начинающихся с маленькой буквы

ожидаемый выход как выход скрипта:

lesson.04/simple/count_words.rb

Совпадает ли количество слов 1. с суммой 2. и 3. ?

Если нет, то выведите строку/и, которая/ые не была/и подсчитана/ы?

Задание

- Из файла data/corpus.txt выведите непустые строки длиной меньше 10 токенов.
- Подсчитайте все непустные строки, пришедшие на вход, и все выведенные строки. Выведите эти счетчики в конце выполнения программы в поток ошибок

Ожидаемый выход как выход скрипта:

lesson.04/simple/short_paragraphs.rb

Начальный скрипт:

lesson.04/simple/short_paragraphs_stub.rb

while
IO#gets
String#length
String#empty?
String#split
Array#length

Accuracy/Precision/Recall

		Gold		
		True (NP)	False (non-NP)	
Auto	Pos. (NP)	tp: NP = NP	fp: NP != non-NP	Precision
	Neg. (non-NP)	fn: non-NP != NP	tn: non-NP = non-NP	
		Recall		

tp - true positive
fp - false positive
fn - false negatve
tn - true negative

Accuracy: (tp + tn) / (tp + tn + fp + fn)

Precision: tp / (tp + fp)

Recall: tp / (tp + fn)

Задание

- Задание: на основании файла corpus_gold_vs_auto.txt подсчитайте accuracy

ответ: precision/compute_accuracy.rb

Задание

- Задание: посчитайте точность распознавания NP.
- Дополнительно: округлите результат до двух знаков после запятой.

начальный скрипт: precision/compute_precision_stub.rb

ответ: precision/compute_precision.rb

Задание

- Задание: посчитайте посчитайте racall распознавания NP.
- Дополнительно: округлите результат до двух знаков после запятой.

ответ: precision/compute_recall.rb

- Задание: объедините в один скрипт вычисление всех метрик: accuracy, precision, recall

Задание

- Задание: измените скрипт find_jj_with_jjr.rb так, чтобы выход имел следующий вид:

NICE JJ --> JJR NICER

(т.е. пять полей разделенных табуляцией)

ответ: lesson.06/find_jj_with_jjr.2.rb

Ожидаемый выход в

lesson.06/find_jj_with_jjr.2.out
lesson.07/find_jj_with_jjr.2.out

Есть ли в выходе это две строки?

```
FAR JJ    -->   JJR  FARTHER
FAR JJ    -->   JJR  FURTHER
```

Задание

- Задание: (см. lesson.06/irrverbs/README) Разработайте скрипт, который находит в словаре просао глаголы, имеющие неправильную форму VBD, и выводит найденное в следующем формате:

```
GIVE    VB  -->  VBD     GAVE
SHED    VB  -->  VBD     SHED
```

(т.е. пять полей разделенных табуляцией)

Используйте DicTester как источник данных. см. пример выхода DicTester в файле:

lesson.06/irrverbs/dictester.txt

ответ: lesson.07/irrverbs/find_vb_irrvbd.rb

ожидаемый выход: lesson.07/irrverbs/find_vb_irrvbd.out

“Найди отличия”

1. Правильный ли это способ получить форму VB?

```
vb = line.split.first
```

см. файл dict.takeplace.txt

```
“TAKE PLACE   classes: VB-134/10”.split
=> ["TAKE", "PLACE", "classes:", "VB-134/10"]
```

2. Что изменится, если заменить регулярное выражение?

```
/^(.+[^\s])\s+classes:/
```

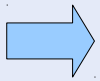

```
/^(.+)\s+classes:/
```

Работает ли скрипт?
Сравните значения переменной vb в обеих реализациях.

```
puts vb + “>”
```

“Найди отличия”

3. Что если изменить порядок проверок условий?

```
line =~ /VB-/ && line =~ /^(.+)\s+classes:/
```

```
line =~ /^(.+)\s+classes:/ && line =~ /VB-/
```

- Чему равно значение переменной vb в каждом из случаев?

4. Нужна ли проверка && vb ? Сравните выход скрипта с и без этой проверки

```
if line =~ /VB-.+--> VBD-\d+ (.+)/ && vb
```

см. файл dict.do.txt

- paradigm of DO has no VB but has VBD

Массивы (Arrays)

- Arrays = массивы = списки
- Массивы один из базовых типов данных

letters = [“a”, “b”, “c”, “d”, “e”]

- Массив это структура данных, содержащая **ряд** объектов, доступ к которым определен **по индексу**.

- обычная переменная (не массив) имеет **одно** значение

age = 25

- В руби массивы индексируются начиная с 0.

ключ	значение
0	“a”
1	“b”
2	“c’
3	“d”
4	“e”

Массивы (Arrays)

- Обращение к элементу массива происходит через указание его индекса

```
letters = [“a”, “b”, “c”, “d”, “e”]

puts letters[0]          “a”

puts letters[3]          “d”
```

- В руби в массиве можно хранить данные разных типов

```
things = [1, “uno”, 36.6, [“one”, “two”], 1..10]
```

- Вопрос: что хранится в массиве things под индексом 3?

```
puts things[3]          [“one”, “two”]      # массив строк
```

Обращение к элементу(ам) массива

- Дан массив

```
letters = [“a”, “b”, “c”, “d”, “e”]
```

- По индексу от начала массива

```
letters[1]          => “b”
letters[1] = ’B’
```

```
ri Array#[]
ri Array#[]=
```

- По индексу считая с конца массива (нумерация начинается с -1)

```
letters[-1]         => “e”      # последний элемент массива
letters[-2]         => “d”      # предпоследний элемент массива
```

Задания

- Задание: как еще можно выделить первый/последний элементы массива?

ri Array	ri Array#first ri Array#last	letters.first letters.last

- letters.second, letters.third, …, letters.onehundredtwentyfirst ?

- Задание: как выделить несколько элементов массива сразу? Как выделить элементы “b”, “c” и “d”?

```
letters = [“a”, “b”, “c”, “d”, “e”]

letters[1,3]        => ["b", "c", "d"]    # первый, длина

letters[2..4]       => ["c", "d", "e"]    # диапазон первый..последний
```

Как задать массив

- Перечислить через запятую значения его элементов

letters = [“a”, “b”, “c”, “d”, “e”] digits = [0, 1, 2, 3, 4, 5, 6, 7, 8, 9]

- Массив **строк** можно задать также таким образом

letters = %w{ a b c d e }

letters = %w(a b c d e)

- Преобразованием другого объекта в массив

строки:	“hello”.split(‘’)	#=> ["h", "e", "l", "l", "o"]
	“hello, world”.split	#=> [“hello,”, ‘world’]
диапазона:	(1..5).to_a	#=> [1, 2, 3, 4, 5]
	(‘a’..’e’).to_a	#=> ["a", "b", "c", "d", "e"]

Добавление элементов в массив

- Объявляем массив

```
letters = Array.new          синоним: letters = []
```

- Здесь new это название метода класса, создающего новый экземпляр массива. Этот метод (*new)* называется *конструктором*.

- Добавление элемента в конец массива при помощи <<

```
letters << “a”                    => [ “a” ]
letters << “a” << “b” << “c”      => [ “a”, “a”, “b”, “c” ]
```

синоним – метод Array#push:

```
letters.push “k”
letters.push(“k”, “l”, “m”)
letters.push “k”, “l”, “m”   # можно без скобок
```

Присвоение значения элементам массива

- Можно назначить значение произвольному элементу массиву

letters[10] = ‘zzz’

Array#[]=

- Задание: какой вид будет иметь массив после выполнения следующих действий

things = [‘a’, ‘b’]
things << ‘k’ << ‘l’
things [10] = ‘zzz’

Ответ: ["a", "b", "k", "l", nil, nil, nil, nil, nil, nil, "zzz"]

- Задание: проверьте, что произойдет, если выполнить следующие действия

words[10] = “hello”

сначала массив надо объявить: words = []

Присвоение значения элементам массива

- Используя метод []= можно назначать значение сразу нескольким элементам массива (по аналогии с получением *нескольких* значений через метод [])

```
letters = %w{a b c d e f g h}
=> ["a", "b", "c", "d", "e", "f", "g", "h"]

letters[1..3] = ["X", "Y", "Z"]
letters
=> ["a", "X", "Y", "Z", "e", "f", "g", "h"]
```

ri Array#[]=

- Что если длина диапазона (в индексе) не совпадает с длиной массива, который присваивается (справа от знака равно)?

```
letters[1..3] = [1,2]
```

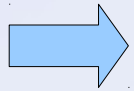

```
=> ["a", 1, 2, "e", "f", "g", "h"]
```

Присвоение значения элементам массива

- Какой вид будет иметь массив после следующих действий?

```
numbers = (0...10).to_a
numbers[2..4] = [ [2, 'dos'], [3, "tres"] ]
```

```
=> [0, 1, 2, 3, 4, 5, 6, 7, 8, 9]
=> [0, 1, [2, "dos"], [3, "tres"], 5, 6, 7, 8, 9]
```

Итераторы

- Чтобы пробежаться по всем элементам массива

letters = %w{ a b c d e f }

Array#each

```
letters.each do | val |
   puts val
end
```

эквивалентно

```
letters.each { |val|
   puts val
}
```

Array#each_index

```
letters.each_index do | idx |
   puts “#{idx} = #{letters[idx]}”
end
```

эквивалентно

```
letters.each_index { | idx |
   puts “#{idx} = #{letters[idx]}”
}
```

- Задание: попробуйте эти вкусные конструкции

Задания

- Задание: выведите элементы этого массива в обратном порядке

```
letters = %w{ a b c d e }
```

ri Array#reverse_each

```
letters = %w{ a b c d e }

letters.reverse_each do |item|
    puts item
end
```

ожидаемый выход:

```
e
d
c
b
a
```

- Задание: и пронумеруйте элементы

bad news: no such thing as Array#reverse_each_index

```
0 e
1 d
2 c
3 b
4 a
```

Задания

- Задание: как еще можно вывести массив в обратном порядке?

letters = %w{ a b c d e }

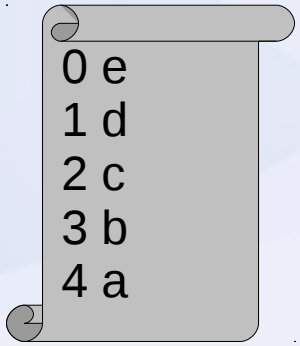


```
letters = %w{ a b c d e }

letters.reverse.each_with_index {|item, i|
  puts "#{i} #{item}"
}
```

- У массива есть много методов, принимающих блок. Блок выполняется для каждого элемента массива. То есть, имеет место неявное итерирование по массиву.

Цикл for

- Цикл **for** синономичен **Array#each**

```
letters =  %w{a b c d e}

for i in letters
    puts i
end
```

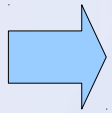

```
a
b
c
d
e
```

- Страшная тайна: **for** вызывает метод **each**, поэтому **for** можно использовать с любым объектом, для которого определен метод **each**

- Что произойдет, если заменить массив на строку?

```
for i in “hello”
    puts i
end
```

```
NoMethodError: undefined method
`each' for "hello":String
```

Задания

- Задание: Посчитайте длины всех слов в списке words.txt

примерный выход (см. lesson.08/word_lengths/word_lengths_1.out)

```
52 words of length 1
183 words of length 2
838 words of length 3
3300 words of length 4
```

ответ:
lesson.08/word_lengths/word_lengths_1.rb

- Задание: то же самое, что и предыдущее задание, но выведите еще по 10 слов на каждую длину (10 первых встретившихся в списке слов)

примерный выход (см. lesson.08/word_lengths/word_lengths_2.out):

```
1 52, A, B, C, D, E, F, G, H, I, J
2 183, Ac, Ag, Al, Am, Ar, As, At, Au, Av, Ba
3 838, A's, AOL, Abe, Ada, Ala, Ali, Amy, Ana, Ann, Apr
```

ответ: lesson.08/word_lengths/word_lengths_ 2.rb

наш друг ri

- ri Array

= Class methods:

[], new, try_convert

= Instance methods:

&, *, +, -, <<, <=>, ==, [], []=, abbrev, assoc, **at**, bsearch, **clear**, **collect, collect!**, combination, **compact, compact!**, **concat, count**, cycle, dclone, **delete, delete_at, delete_if**, drop, drop_while, **each, each_index, empty?**, eql?, fetch, fill, find_index, **first, flatten, flatten!**, frozen?, hash, **include?, index**, initialize_copy, i**nsert, inspect, join, keep_if,** last, **length**, **map, map!**, pack, permutation, **pop**, **pretty_print**, pretty_print_cycle, product, **push**, rassoc, **reject, reject!**, repeated_combination, repeated_permutation, **replace**, **reverse, reverse!**, **reverse_each**, **rindex**, rotate, rotate!, **sample, select, select!**, shelljoin, **shift**, shuffle, shuffle!, **size**, **slice, slice!**, **sort, sort!, sort_by!**, take, take_while, to_a, to_ary, **to_s**, transpose, **uniq, uniq!, unshift, values_at**, zip, |

Получение несоседних значений из массива

- Дан массив (см. lesson.09/data)

  @months = %w[Jan Feb Mar Apr May Jun Jul Aug Sep Oct Nov Dec]

- Загрузите этот массив из файла (выполнить в irb)

```
load ‘data’

@months
```

ri Kernel#load

@ глобальная переменная

- Попробуйте загрузить таким же образом файл data.2 и доступиться к массиву days, который там определен.

- Задание: выделите одной командой все весенние и два первых осенних месяца, например, по их индексам в массиве

  ["Mar", "Apr", "May", "Sep", "Oct"]

ri Array#values_at

```
@months.values_at(2..4, 8, 9)
```

селекторами могут быть диапазоны или целые числа (положительные или отрицательные)

Методы, оканчивающиеся на ? и !

- Имена методов могут *заканчиваться* на знаки ! и ?

Array#empty?	String#empty?
Array#include?	String#include?

- Вопрос: что это может обозначать? почитайте в ri описание разных методов с ?

описания в ri начинаются с **Returns true if ...**

- Такие методы (предикаты) всегда возвращают булевское **true** или **false**.

```
[].empty?                  #=> true, да массив пуст
%w[a b c].empty?           #=> false, нет, массив не пуст

arr =  [“one”, “two”, “three”]
arr.member?('one')         #=> true
arr.include?(1)            #=> false
```

Синонимы
Array#member?
Array#include?

Опасные методы

- Знак ! (bang) обозначает, что метод “опасный”. Всегда есть метод без ! и метод с ! есть его “опасный” вариант

- Парные методы объектов класса Array

collect	collect!	map map!
compact	compact!	
flatten	flatten!	
reject	reject!	
reverse	reverse!	
rotate	rotate!	
select	select!	
slice	slice!	
sort	sort!	
sort_by	sort_by!	
shuffle	shuffle!	
uniq	uniq!	

Опасные методы - 2

- В такой паре методов метод с ! изменяет *ресивер* (объект, у которого метод вызывается), а метод без ! возвращает другой объект, содержащий изменение:

arr = [1, 2, nil, 4]

- Сравните (в irb)

```
arr.compact
#=> [1,2,4]

arr
#=> [1, 2, nil, 4]
```

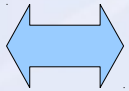

```
arr.compact!
#=> [1,2,4]

arr
#=> [1, 2, 4]
```

методы с ! тоже что-то возвращают

Опасные методы - 3

- Много других методов -- без ! -- также изменяют ресивер:

  Array#delete
  Array#push

  пример Array#delete см. lesson.09/find_vb_incomplete_pdg.2.rb

- Очень распространенное неправильное обобщение: если метод изменяет ресивер, то он должен иметь ! .

  Нет, это верно только для парных методов.

String#chomp	String#chomp!
String#strip	String#strip!

Задания

- Мысленно выполните скрипт lesson.09/test_compact.rb

- Вопрос: сколько элементов содержит массив @months в конце выполнения скрипта?

```
puts @months.length
#=> 12
```

- Как удалить из массива все nil? Сколько элементов содержит сейчас массив @months?

```
@months.compact!
puts @months.size
```

```
@months = @months.compact
puts @months.length
```

Array#delete

Array#length
Array#size
Array#count

Строковое представление массива

- Пребразование массива в строку

Array#to_s

ruby1.8.7

```
puts [1,2,3,4].to_s
#=> 1234

puts [1,2,3,4].inspect
#=> [1, 2, 3, 4]
```

ruby 1.9.x

```
puts [1, 2, 3, 4].to_s
#=> [1, 2, 3, 4]

puts [1,2,3,4].inspect
#=> [1, 2, 3, 4]
```

Строковое представление массива - 2

- Пребразование массива в строку

Array#join(sep=$,)

$, – output field separator
по умолчанию равно nil

```
arr = [1,2,3,4]

puts arr.join          #=> 1234

puts arr.join(', ')    #=> 1, 2, 3, 4
```

Строковое представление массива - 2

- Пребразование массива в строку

Array#join(sep=$,)

$, – output field separator
по умолчанию равно nil

```
arr = [1,2,3,4]

puts arr.join          #=> 1234

puts arr.join(', ')    #=> 1, 2, 3, 4
```

Method chaining

- Сцепление методов

```
nums = %w[one two three four]

str = nums.sort.reverse.join('-')
```

str = "two-three-one-four"

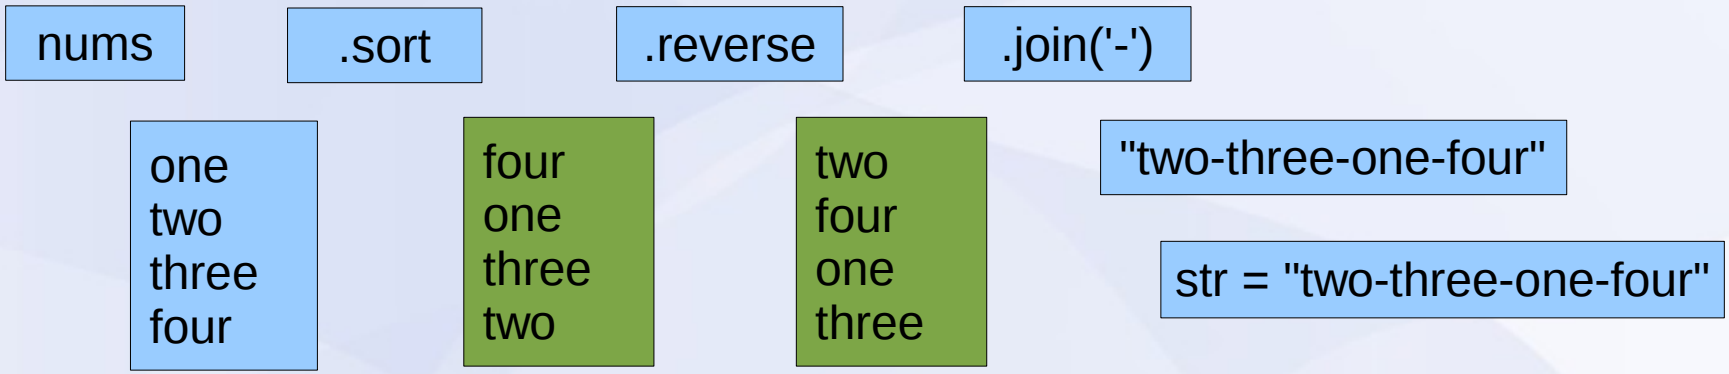

- в процессе выполнения создаются промежуточные временные объекты
- Какой вид имеет массив nums после этих манипуляций?

массив nums не изменился

Задание

- Замените методы на их опасные варианты. Чему будет равно str? Какой вид будет иметь массив nums после этих манипуляций?

```
str = nums.sort!.reverse!.join('-')
```

str = "two-three-one-four"

nums = ["two", "three", "one", "four"]

- Здесь .sort! и .reverse! не создают никаких временных объектов, а изменяют свой ресивер.

Отображение множества

- Отображение множества строчных букв на множество прописных

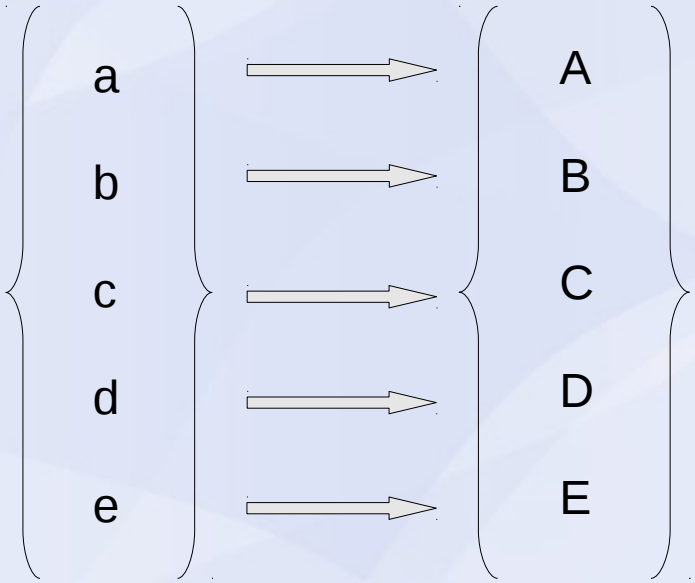


```
chars = %w{a b c d e}
upchars = chars.map do |char|
    char.upcase
end
```

- Отображение множества слов на их длины

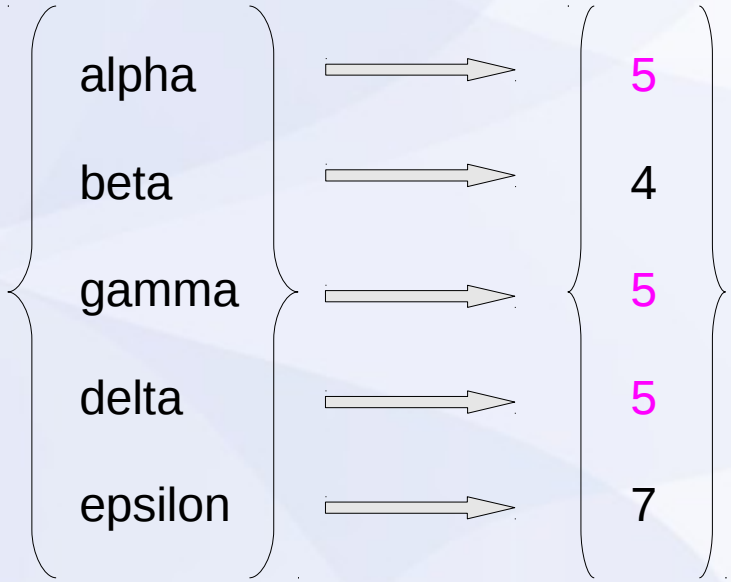

Отображение множества

- Метод map (map!) обходит массив и для каждого элемента выполняет указанные действия, создавая из результата новый массив (или замещая текущий элемент этим результатом)

Синонимы
Array#map Array#collect

Синонимы
Array#map! Array#collect!

```
chars = %w{a b c d e}
upchars = chars.map do |char|
    char.upcase
end
```

```
chars = %w{a b c d e}
chars.map! do |char|
    char.upcase
end
```

- Что находится в массивах chars и upchars в обоих случаях?

chars – не изменился
upchars = [“A”, “B”, “C”, “D”, “E”]

chars = [“A”, “B”, “C”, “D”, “E”]
какой еще upchars? :-)

Array#map (cont'd)

- В блоке может быть больше одного действия.

см. lesson.10/test_map_1.rb

- Результат *последней* операции в блоке является результатом всего блока и именно это значение помещается в новый массив (или замещает прежнее значение, в случае Array#map!).

```
things = %w[ 1 uno 234 dos ]
things.map! do |el|
    if el =~ /^\d+$/
        el.to_i
    else
        el.upcase
    end
    “HELLO”
end
```

см. lesson.10/test_map_things.rb

- Что произойдет в результате выполнения этого кода?

things = [1, "UNO", 234, "DOS"]

- Что произойдет, если добавить перед end “HELLO”?

["HELLO", "HELLO", "HELLO", "HELLO"]

Задания

- Измените скрипт lesson.10/test_map_1.rb таким образом, чтобы получить из массива @numbers двумерный массив вот такого вида:

[["uno", "UNO"], ["dos", "DOS"], ["tres", "TRES"], ...]

Ответ: lesson.10/test_map_2.rb

- Найдите максимальную и минимальную длину слов из @numbers

ожидаемый результат:

```
min: 3
max: 6
```

Array#min
Array#max

Ответ: lesson.10/test_map_3.rb

Состояние после маппирования:

```
@numbers.map {|item| item.length}
#=> [3, 3, 4, 6, 5, 4, 5, 4, 5, 4]
```

Задания

- Как иначе получить максимальное и минимальное значения (не используя методы Array#min и Array#max)?

```
@numbers.map do |item|
    item.length
end
```

#=> [3, 3, 4, 6, 5, 4, 5, 4, 5, 4]

```
@numbers.map do |item|
    item.length
end.sort
```

#=> [3, 3, 4, 4, 4, 4, 5, 5, 5, 6]

```
array.first
array.last
array[0]
array[-1]
```

```
min, max = array.values_at(0, -1)
```

Задания

- Дано теггированное предложение. Необходимо вывести:
  - предложение без тегов
  - цепочку тегов (без слов)

Ограничение: нельзя использовать String#gsub на всем предложении, но можно использовать его для одного слова.

входной файл: lesson.10/tagged.txt

аккуратно преобразовать фразы:

as_well_RB

Array#split
Array#index
Array#rindex
String#gsub

ответ: lesson.10/untag.rb

(Домашнее) Задание

- Даны теггированные отношения r__VerbPhrase. Необходимо вывести их без тегов.

Изучите структуру r__VerbPhrase (используйте метод inspect)

Возможно пригодятся:

Array#shift
Array#unshift

входной файл: lesson.10/tagged_relations.txt

ответ: lesson.10/untag_relations.rb

Квантор всеобщности и квантор существования

- Квантор всеобщности – условие, верное для всех элементов множества

Array#all?

#=> true если **все** элементы удовлетворяют условию
#=> false если **хотя бы один** элемент **не** удовлетворяет условию

```
pets = %w{ bat dog cat cow wombat }

pets.all? do |pet|
    pet =~ /a/
end
```

- Все ли слова содержат букву а?

#=> false

- Каким будет результат следующей операции?

```
pets.all? do |pet|
    pet =~ /[ieaou]/
end
```

#=> true

Квантор существования

- Позволяет проверить, есть ли **хотя бы один** элемент, удовлетворяющий данному условию.

Array#any?

#=> true если **хотя бы один** элемент удовлетворяет усл.
#=> false если **ни один** элемент **не** удовлетворяет условию

- Когда надо выполнить действие, если среди тегов есть хотя бы один глагольный:

```
tags = [ “NN”, “VBG”, “JJing” ]

if tags.any? { |tag| tag =~ /^V/ }
    # do something
end
```

Как не надо делать

- Когда надо выполнить действие, если среди тегов есть хотя бы один глагольный:

```
if tags.include?(“VB”) || tags.include?(“VBZ”)
   || tags.include?(“VBD”) || tags.include?(“VBN”)
   || tags.include?(“VBG”)
then
   # do something
end
```

- Зачем здесь break?

Чтобы выполнить действие только один раз

```
tags = [ “NN”, “VBG”, “JJing” ]
tags.each do |tag|
  if tag =~ /^V/
    # do something
    # ...
    break
  end
end
```

Проверка на наличие элемента в массиве

```
pets = %w{ bat dog cat cow wombat }

if pets.include?('dog')
   ...
end
```

Синонимы
Array#include?
Array#member?

- Объясните, почему это тоже работает аналогичным образом

```
if pets.index('dog')
   # мы здесь
end
```

```
if pets.index('aircraft')
   # сюда мы не попадем
end
```

Array#index(val)

Array#rindex(val)

- возвращает позицию самой левой (первой) встречи val
- возвращает позицию самой правой (последней) встречи val

NB: позиция всегда отсчитывается от начала

Проверка на наличие подстроки в строке

- Похожим образом работают одноименные методы в String

String#index
String#rindex

- Закончите мысль

```
if “abrakadabra”.index(“k”) …
    puts “В этом слове одна буква k”
end
```

#=> 4

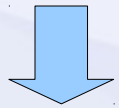

#=> 4

```
if “abrakadabra”.index(“k”) == “abrakadabra”.rindex(“k”)
    puts “В этом слове одна буква k”
end
```

- Как проверить, что в слове больше одной буквы b?

заменить == на !=

Задание

- Из файла lesson.11/searching/text.txt выведите предложения, содержащие хотя бы одно слово в середине, написанное в Titlecase.

  Не используя String#=~ на все предложение.
  Представьте предложение в виде массива слов.

ответ: lesson.11/finding/select_sent_with_titlecase_inside.rb

ответ: lesson.11/finding/select_sent_with_titlecase_inside.2.rb

Array#shift

Selecting element(s)

- Найти и выбрать из массива элемент(ы), удовлетворяющие некоторому условию?

- Даны среднемесячные температуры в г. Надым. Как найти первую положительную температуру

temperatures = [-19.6, -18.2, -11.8, -7.6, 1.2, 10.6, 16.0, 12.1, 4.9, -19, -20, -25]

ответ в lesson.11/selecting/first_warm_month_temp.rb

```
temperatures.find {|el| el > 0}
```

#=> 1.2

Синонимы
Array#find
Array#detect

Selecting element(s) - 2

- Чем отличается Array#select отличается от Array#find?
- Что вернет следующий код?

```
temperatures = [-19.6, -18.2, -11.8, -7.6, 1.2, 10.6, 16.0, 12.1, 4.9, -19, -20, -25]
```

```
temperatures.select {|temp| temp > 0}
```

#=> [1.2, 10.6, 16.0, 12.1, 4.9]

то есть, **массив** всех подходящих значений

temperatures = [-19.6, -18.2, -11.8, -7.6, 1.2, 10.6, 16.0, 12.1, 4.9, -19, -20, -25]

см. также Array#grep

Сортировка массива, метод <=>

- Array#sort, Array#sort!

```
words = %w{  pear apple strawberry apple bears }

words.sort      #=> ["apple", "apple", "bears", "pear", "strawberry"]
```

- Элементы сравниваются между собой при помощи оператора <=> .

```
str <=> other_str
```

=> -1, 0, +1

“spaceship” operator

```
ri '<=>'
ri 'String#<=>'
```

Возвращаемые -1, 0 или 1 показывают,
где по отношению к other_str сортируется str

- -1 если str сортируется **перед** other_str
- 1 если str сортируется **после** other_str
- 0 если равны

Оператор “космический челнок” <=>

- Что вернут следующие сравнения?

```
'apple' <=> 'apple'      #=> 0
'apple' <=> 'bears'      #=> -1   apple сортируется перед bears
‘bears’ <=> ‘apple’      #=> 1    bear сортируется после apple
‘apples’ <=> ‘apple’     #=> 1
```

- На метод <=> опираются все другие методы сравнения, определенные в модуле-примеси (mixin) Comparable:

< <= == >= >

Сортировка массива с блоком

- методы sort и sort! могут принимать блок, в котором описана процедура сравнения двух элементов. блок должен возвращать -1, 0, 1

- Array#sort (без блока) эквивалентен следующей команде с блоком

```
arr.sort do |a, b|
    a <=> b
end
```

два элемента попадают в переменные a и b

как взаимно расположить a и b?

если -1 или 0, то ab; если 1, то ba

- Как отсортировать массив в обратном порядке (от большего к меньшему), не используя Array#reverse ?

```
sorted = arr.sort.reverse
```

```
arr.sort do |a, b|
    b <=> a
end
```

см. lesson.11/sorting/test_sort_1.rb

Задания

- Отсортируйте массив @numbers по длине слов

```
@numbers.sort do |a, b|
    a.length <=> b.length
end
```

см. lesson.11/sorting/test_sort_2.rb

- Как этот же массив отсортировать в обратном порядке, от больших длин к меньшим?

```
@numbers.sort do |b, a|
    a.length <=> b.length
end
```

см. порядок аргументов в |b, a|

Сортировка по вычисленному значению

- sort_by, sort_by! производят сортировку по вычисленному значению

```
%w{ three one 1984 }.sort_by {|item|
    item.length
}
```

см. lesson.11/sorting/test_sort_by_1.rb

#=> ["one", "1984", "three"]

- Исследуйте, что делает скрипт lesson.11/sorting/test_sort_by_2.rb

Ответ: сортирует по согласным буквам

["ocho", "cinco", "cuatro", "dos", "diez", "uno", "nueve", "seis", "siete", "tres"]

Задания

- Измените test_sort_by_2.rb так, чтобы слова были отсортированы по количеству гласных в слове

["dos", "tres", "seis", "diez", "cinco", "uno", "ocho", "siete", "nueve", "cuatro"]

ответ см: lesson.11/sorting/test_sort_by_3.rb

- Отсортируйте массив @trn_numbers по немецким словам

```
@trn_numbers = [
    [1, "one",   "ein"],
    [2, "two",   "zwei"],
    [3, "three", "drei"],
    [4, "four",  "vier"],
    [5, "five",  "fünf"]
]
```

см. lesson.11/sorting/test_sort_3.rb
см. lesson.11/sorting/test_sort_by_5.rb

Пользовательские методы

Пользовательские методы

- Программист может задавать свои собственные методы
- Метод это способ сгруппировать код в одном месте
  - возможность абстрагировать от деталей реализации
  - возможность повторного использования (reusability)
  - более читабельный код
  - легче поддерживать
- синонимы: подпрограммы, функции, процедуры

Определение метода и его использование

- Метод должен быть *определен* до его *использования*
- Определение метода

```
def method_name(arg1, arg2....)
   # команды
   return ...
end
```

```
def method_name arg1, arg2....
   # команды
   return ...
end
```

- Использование (вызов) метода (method call):

```
res = method_name(a1, a2)
```

```
res = method_name a1, a2
```

- см. пример использования методов в

lesson.12/methods/extract_random_subcorpus.3.rb
lesson.12/methods/extract_random_subcorpus.4.rb

Аргументы методов

- Имена аргументов это *локальные названия* для внешних (по отношению к методу) переменных и литералов.

```
def unvowel(word)
    word.delete('ieaou')
end

unvowel("hello")


w = "good bye"
unvowel(w)
```

внутри метода unvowel переменная word принимает значение "hello"

внутри метода unvowel переменная word принимает значение "good bye"

Аргументы методов

- Аргументы передаются позиционно

```
def max_of_ three(a, b, c)
    if a > b && a > c
        return a
    elsif a > b && a < c
        return c
    elsif …
        ...
    end
end

x, y = 1, 20
max_of_three(x, y, 10)
```

при вызове метода происходит

```
max_of_ three(x, y, 10)
```

```
max_of_ three(1, 20, 10)
```

```
def max_of_ three(a, b, c)
```

```
max_of_ three(a=1, b=20, c=10)
```

Задание

- Реализуйте метод max_of_three иначе.

ответ:

lesson.12/methods/max_of_three.2.rb
lesson.12/methods/max_of_three.3.rb

example of in-place unit testing:

```
puts max_of_three(1, 100, 2) == 100
puts max_of_three(1, 100, 2, 500_000) == 500000
```

```
#=> true
#=> true
```

Передача объектов в метод

- Объекты, передаваемые в метод через аргументы, передаются
  - по значению (по копии)
  - по ссылке
- Задание: исследуйте скрипт lesson.12/methods/test_args_2.rb. Что произошло со строкой str и почему?
  - Метод object_id применяется к любой сущности в руби, возвращая идентификатор этой сущности (объекта) в памяти.
- Задание: Исследуйте скрипт lesson.12/methods/test_args_3.rb. Изменилось ли значение переменной i после вызова метода? Как можно объяснить, что внутри метода переменная i сначала имеет один object_id а потом другой?

Это надо знать!

- Простые объекты (числа, true, false, nil) передаются по копии (в руби – при попытке их изменить, делается и изменяется копия).
- Сложные объекты (String, Array, Hash, etc) передаются по ссылке -- такой объект можно изменить (в том числе по неосторожности).
- Это же отличие можно наблюдать в множественном присваивании:

два разных объекта a и b

```
a = b = 10

a += 10
b
```

```
#=> 20
#=> 10
```

две переменные aa и bb ссылются на один и тот же объект

```
aa = bb = [1,2,3]

aa << 4
bb
```

```
#=> [1,2,3,4]
#=> [1,2,3,4]
```

Область видимости переменных

- Область видимости (visibility scope) – фрагмент(ы) программы, где переменная видна (и ее можно использовать)

- Виды переменных
  - глобальные ($zzz) – доступны везде: $stdout, $stderr, $1..
  - локальные (без @ в начале)
  - **переменные объекта класса** (начинаются с @zzz)
  - переменные класса (начинаются с @@zzz)

- Метод создает свой собственный *локальный* контекст, переменные внутри метода никак не конфликтуют с переменными вне этого контекста, даже если их имена совпадают.

- Переменные с @ являются “глобальными” для скрипта и видны внутри всех методов, определенных в скрипте

Локальные переменные

- Локальная переменная видна только в локальном контексте

```
def increment(b)
    b += 1
end

b = 10

puts increment(b)
puts b
```

эта переменная b является локальной для метода increment

эта переменная b является локальной для скрипта (вне методов)

```
#=> 11
#=> 10
```

- Это разные переменные b, они существуют в разный областях видимости

Переменные с @

- Переменная объекта класса (@name) видна во всем скрипте

```
def increment
    @b += 1
end

@b = 10

puts increment
puts @b
```

#=> 11
#=> 11

- Задание: в скрипте lesson.12/methods/extract_random_subcorpus.3.rb сделайте переменную *pct* видимой внутри метода.

ответ: lesson.12/methods/extract_random_subcorpus.5.rb

  - Недостаточно заменить pct на @pct. Когда переменная стала глобальной для скрипта, нет необходимости передавать ее в метод как аргумент.
  - Метод стал менее универсальным.

Return

- Метод может возвращать какое-либо значение. Для этого используется ключевое слово **return**
  - возвращает указанное значение
  - и выходит из метода

- В руби при помощи return можно вернуть любое количество любых объектов (руби объединяет их в массив)

```
def useless_method
    a = 111
    b = 222
    return a, b, 42
end
```

```
x, y, z = useless_method
```

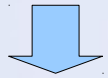

```
x, y, z = 111, 222, 42
```

~~Come back~~ Return

- Что делает этот метод?

```
def longer_word(word1, word2)

    if word1.length > word2.length
        return word1
    end

    return word2

    puts "hello"  # this never happens
end
```

- return выходит из метода

- Что будет напечатано?

```
w = "books"
puts longer_word("book", w)
```

#=> books

- Чему равно res ?

```
w = "burn"
res = longer_word "book", w
```

res = "burn"

Задания

- Разработайте метод, который принимает массив чисел и возвращает минимальное и максимальное значения.

```
values = [3,2,5,9,1,-7]

mn, mx = min_max(values)
```

выход:
min = -7
max = 9

ответ lesson.12/methods/min_max.1.rb

- Объясните, что вы видите в lesson.12/methods/min_max.2.rb?

Задание

- Определите метод select_by_length, который из заданного массива выбирает слова заданной длины

```
dict = %w{cat act book teacher Ruby}

res = select_by_length(dict, 4)
```

Ожидаемый результат:

#=> ["book", "Ruby"]

ответ: lesson.12/methods/select_by_length.rb

Методы без Return

- Метод не обязательно должен что-либо возвращать
  - метод изменяет сам объект, переданный ему как аргумент
  - метод выполняет какое-то действие, возвращаемое значение которого *не важно*

```
def greet(name)
      puts “Hello, #{name}.”
end
```

```
greet “Zeus”

greet( ‘Apollo’ )
```

- В руби метод без явного *return* возвращает результат последней операции!

- Вопрос: будет ли напечатан вопрос про гору Олимп?

```
if greet(“Zeus”)
      puts “How is the life on the Mount Olympus?”
end
```

не будет, так как puts возвращает nil, а nil это false

Параметры по умолчанию

- Аргументам метода можно задавать значение по умолчанию

Array#join(sep=$,)

```
arr = %w{uno dos tres}
puts arr.join        #=> unodostres
puts arr.join(', ')  #=> uno, dos, tres
```

- Допускается любое количество опциональных аргументов при условии, что они являются *последними* аргументами в методе

```
def strjoin(a, b, c=nil, s=" ")
    [a,b,c].compact.join(s)
end
```

```
puts strjoin("aa", "bb", "cc", "\t")   #=> aa    bb    cc
puts strjoin("aa", "bb", "cc") + "!"   #=> aa bb cc!
puts strjoin("aa", "bb") + "!"         #=> aa bb!
puts strjoin("aa", "bb", "\t")  + "!"  #=> aa bb    \t!
```

- Вопрос: Что напечатают следующие команды?
- Вопрос: как напечатать “aa   bb” разделенные табуляцей?

```
puts strjoin("aa", "bb", nil, "\t")  #=>"aa    bb"
```

Переменное количество аргументов

- В том случае, если функция должна иметь возможность вызываться с разным количеством элементов, используется * (splat operator)

```
def method_name( *args )
    # args is an Array
    # args[0], args[1] ...
end
```

Использование:

```
method_name(1)
method_name(1, “aa”)
method_name(1, “aa”, x, y)
```

- Задание: разработайте метод *strjoin*, который производит конкатенацию заданных строк в одну через заданный сепаратор, принимая любое число строк для конкатенации в качестве аргументов.

```
puts strjoin("aa", "bb", ",")          #=>aa,bb
puts strjoin("aa", "bb", "cc", "\t")   #=>aa    bb    cc
```

ответ: lesson.13/strjoin.rb

Задание

- Будет ли работать такой код?

```
def strjoin(*args, sep="\t")
    args.join(sep)
end
```

см. lesson.13/strjoin.rb

Какой будет результат в случае:

strjoin("aa", "bb", "cc", "\t")

strjoin("aa", "bb", "cc", "dd")

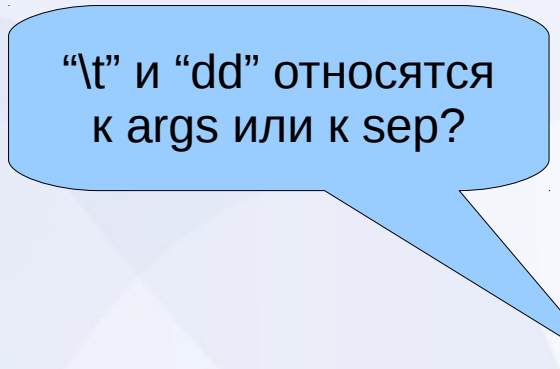

(и снова) Циклы

- Ранее изученные циклы и методы для итерирования:

  while for … in ... Array#each Array#reverse_each

- По диапазону

```
(3..7).each {|i| puts i}
```

#=>

```
3
4
5
6
7
```

- Как вывести числа из диапазона в обратном порядке?

  см. lesson.13/loops/test_range_each.rb

Методы upto/downto

- Цикл от одного заданного значения до другого заданного с шагом 1

```
3.upto(7) do |n|
  puts n
end
```

#=>

```
3
4
5
6
7
```

Integer#upto
String#upto
Date#upto

- downto – от большего к меньшему

```
7.downto(3) do |n|
  puts n
end
```

#=>

```
7
6
5
4
3
```

см. lesson.13/loops/test_upto.1.rb

пример с Date#upto
lesson.13/loops/test_upto_date.rb

- Исследуйте скрипт lesson.13/loops/test_downto.2.rb. Нужно ли брать в скобки (если да, то зачем):

```
(words.length-3).downto {|i| ...}
```

Метод (который танцует) step

- Что делает метод step?

см. lesson.13/loops/test_step_1.rb

```
1.step(20, 3) do |n|
   print n.to_s + ' '
end
```

#=> 1 4 7 10 13 16 19

перебор значений с шагом 3

- Задание: измените test_step_1.rb так, чтобы было выведена следующая последовательность (в обратном порядке):

20 17 14 11 8 5 2

```
1.step(20, -3) do |n|
   print n.to_s + ' '
end
```

ответ в lesson.13/loops/test_step_2.rb:

Метод step

- Метод step определен для классов Range, *Numeric*, Date

ri step

ri Numeric

- Почему метод upto определен для (под)класса Integer, а метод step для родительского (супер)класса Numeric?

```
3.14.upto(9.8) { |n| block }
```

Integer < Numeric

Numeric < Object

Неясно, какое должно быть следующее число за 3.14 – 3.141 или 3.15

Задание

- Реализуйте метод сортирующий массив чисел по алгоритму сортировки вставкой. Метод должен принимать на вход один аргумент - массив чисел – и возвращать *новый массив*, в котором эти числа отсортированы в восходящем порядке.

Array#insert

insert_sort [9,7,9,1,5,-3] #=> [-3,1,5,7,9,9]

начальный скрипт: lesson.13/insert_sort/insert_sort_to_new_stub.rb

ответ: lesson.13/insert_sort/insert_sort_to_new.rb

взять очередной элемент из массива	положить в подходящее место в новом массиве
[9, 7, 9, 1, 5, -3]	[9]
[9, 7, 9, 1, 5, -3]	[7, 9]
[9, 7, 9, 1, 5, -3]	[7, 9, 9]
[9, 7, 9, 1, 5, -3]	[1, 7, 9, 9]
[9, 7, 9, 1, 5, -3]	[1, 5, 7, 9, 9]
[9, 7, 9, 1, 5, -3]	[-3, 1, 5, 7, 9, 9]

Задание

- Реализуйте метод, производящий сортировку массива чисел на месте (in place - переупорядочивается сам массив непосредственно). Используйте алгоритм сортировки вставкой.

Алгоритм и псевдокод:

http://ru.wikipedia.org/wiki/Сортировка_вставкой

начальный скрипт: lesson.13/insert_sort/insert_sort_in_place_stub.rb
ответ: lesson.13/insert_sort/insert_sort_in_place.rb

Модули

everything you always wanted to know
but were afraid to ask

Модуль

- Модуль - набор методов, сгруппированных по назначению и вынесенных в отдельный файл
  - возможность повторного использования в разных скриптах

модуль Math
cos
sin
tan

модуль Church
cross
sin
prayer

  - помещение метода в модуль позволяет иметь одноименные методы с разной функциональностью

Определение и использование

- Коллекция методов, работающих с теггированным текстом

syn.rb

```
module Syn

  def self.untag(tagged)
    tagged.gsub(/_[^_\s]+/, “”)
  end

  def self.unword(tagged)
    ...
  end

end
```

syn.rb

```
module Syn

  def Syn.untag(tagged)
    tagged.gsub(/_[^_\s]+/, “”)
  end

  def Syn.unword(tagged)
    ...
  end

end
```

- Использование:

```
Syn.untag( 'runs_VBZ' )   #=> “runs”
```

- позже о том, как сделать, чтобы работало вот так:

```
“runs_VBZ”.untag
```

Подключение модуля

- Модуль необходимо загрузить (обычно вверху файла)

```
require 'filename'
```

ri Kernel#require

например:

```
require 'syn.rb'
```

ri Kernel#require_relative

или без расширения:

```
require 'syn'
```

в этом случае руби будет искать имена syn.rb, syn.so, syn.o, syn.dll

см lesson.14/modules/test_syn_module.rb

```
require './syn'
```

не следует задавать относительные пути

```
require_relative 'syn'
```

поиск начнется с текущей директории

Настоящее повторное использование

- Цель: сделать так, чтобы ruby мог найти файл с модулем

```
require “syn”
```

- В каких директориях require ищет файлы?

```
> ruby -e 'puts $:'
```

```
$:
$LOAD_PATH
```

массив содержит пути, в которых ищет require

- Переменная окружения RUBYLIB (добавить в .bashrc)

```
export RUBYLIB=~/lib:~/rufsl/lib:$RUBYLIB
```

без пробелов вокруг =

После чего необходимо перезапустить терминал (сигвин) или выполнить команду

```
> source ~/.bashrc
```

Задание

- Создайте директорию для собственных модулей (например lib в домашней директории) и настройте сигвин так, чтобы эта директория была в RUBYLIB.

создать директорию:

```
> mkdir ~/lib
```

добавить в .bashrc:

```
export RUBYLIB=~/lib:$RUBYLIB
```

- Создайте (в ~/lib) модуль Syn (можно взять lesson.14/modules/syn.rb) и добавьте в него метод words, который принимает на вход теггированную строку и возвращает все слова (без тегов) как массив.

один из способов решения:
использовать уже существующий
в модуле метод untag

```
def self.words ts
    untag(ts).split
end
```

- Методы внутри модуля могу вызывать друг друга без явного указания имени модуля в качестве ресивера (т.е. не Syn.untag и просто untag)

Домашнее задание

- Реализуйте следующие методы модуля Syn
  - tags — принимает через аргумент теггированное предложение, возвращает все теги в виде массива
  - unwdc — принимает через аргумент теггированное предложение, возвращает это же предложение, но с объединенными в одно слово компаундами. все внутренние теги сложных слов начинаются на wdc (wdcEL, wdcSN, wdcSJ, wdcSV, wdcLK)

```
das_ATDNN H_wdcEL -_wdcLK Bomben_wdcEL versuch_NCNSN
=>
das_ATDNN H-Bombenversuch_NCNSN
```

  - какие-нибудь другие методы, по желанию

По желанию, разработайте тесткейсы для этого модуля (см. дальше).
Используйте шаблон из lesson.14/modules/unit_test_stub.rb

Именование модулей и файлов

- имя модуля (и класса) является константой руби - должно начинаться с большой буквы

- CamelCase в имени модуля, snake_case в имени файла

имя модуля	имя файла
Syn	syn.rb
MySuperSin	my_super_sin

Модули-примеси (mixin)

- Сравните определения и способы вызова

этот модуль можно подмешать к классу

```
module Syn

  def self.untag
    ...
  end

end
```

```
module Syn

  def untag
    ...
  end

end
```

нет self

подмешанные методы становятся собственными методами объектов

```
class String
  include Syn
end
```

подмешивание к классу String

Использование:

```
Syn.untag("runs_VBZ")
```

```
"runs_VBZ".untag
```

см. lesson.14/modules/syn_as_mixin.rb

+ и -

- Плюсы: примеси позволяют легко добавить однотипную функциональность в несколько классов
- Минусы: примеси загрязняют стандартные классы
  - Что, если кто-то другой уже добавил в класс String метод untag с другим поведением?

Вложенные модули

- Структурирование модулей (и классов) в сложной системе

```
module ESE
  module Tagger
    def self.method1
    end
  end

  module Extractor
    def self.method1
    end
  end
end
```

ese/tagger.rb

```
module ESE
  module Tagger
    def self.method1
    end
  end
end
```

ese/extractor.rb

```
module ESE
  module Extractor
    def self.method1
    end
  end
end
```

использование:

ESE::Tagger::method1 fully-qualified name

ESE.Tagger.method1

TDD с использованием Test::Unit

- см Unit::Test в lesson.14/modules/test_quality.rb

```
class TestQuality < Test::Unit::TestCase
```

- Чтение:

  http://en.wikibooks.org/wiki/Ruby_Programming/Unit_testing

Задание

- Разработайте модуль Quality согласно тесткейсам, которые заданы в lesson.14/modules/test_quality.rb

ответ: lesson.14/modules/quality.rb

- По желанию добавьте в модуль что-нибудь свое, например, вычисление F-Measure.

- По желанию добавьте тесткейсы в файл с тестами test_quality.rb

Hash

в питоне: Dictionary

Hash

- Хэш (ассоциативный массив) *неупорядоченная (?)* коллекция пар "ключ-значение".
- Ключи в *массиве* (индексы) это целочисленный значения (от 0 и выше).

```
arr_months = [ “January”, “February”, “March” ]
```

arr = []

- Ключом в *хэше* может быть любой объект (строки, числа, символы, массивы...). Ключ должен быть уникальным.

не путать с %w{ … }

```
hash_months = {
    "Jan" => "January",
    "Feb" => "February",
    "Mar" => "March"
}
```

```
hash_months = {
   1 => "January",
   2 => "February",
   3 => "March",
}
```

hsh = {}

ri Hash#[]

```
hash_months["Jan"]   #=> "January"
hash_months[2]   #=> "February"
```

- Значением в хэше (как и в массиве) может быть любой объект.

Hash

- Сколько ключей в этом хэше?

```
hash = { 1 => 'one', "1" => 'uno' }
```

#=>2

ri Hash#length

- Еще один способ инициализации хэша, появился в ruby 1.9

```
numbers = { one: 'uno',   two: 'dos',    three:'tres' }
```

- Какому классу принадлежат ключи хэша numbers?

см. lesson.15/test_hash_with_colons

классу Symbol

- Исследуйте, будет ли работать это?

```
hash = { 1: 'uno' }
```

```
hash = { "two": "dos" }
```

в обоих случаях ошибка

Изменение хэша

- Метод []= добавляет или замещает пару ключ-значение

```
hash_months["Apr"] = "April"
```

ri Hash#[]=

```
hash_months ["May"] = "Can"
hash_months ["May"] = "May"
```

останется только эта пара

ключи в хэше являются уникальными

- Синоним: метод Hash#store

```
hash_months.store("Jun", "June")
hash_months.store "Jul", "July"
```

ri Hash#store(key, value)

Вопросы к Хэшу?

- Какой метод позволяет узнать, есть ли в хэше какие-нибудь данные?

```
Hash#empty?
```

hash_months.empty? #=>false

- Как узнать, есть ли в хэше некоторый **ключ**?

```
has_key?(k)
key?(k)
include?(k)
member? (k)
```

hash_months.key?(“Jan”) #=> true

hash_months.key?(“January”) #=> false

- Как узнать, есть ли в хэше некоторое **значение**?

```
Hash#value?(v)
Hash#has_value?(v)
```

hash_months.value?(“January”) #=> true

Получение данных из хэша - 1

- Метод [] позволяет получить значение по указанному ключу

```
hash_months["Jan"]    #=> "January"
```

ri Hash#[]

- Чтобы получить значения по нескольким ключам?

Hash#values_at

поиск ключа происходит:
1) с учетом регистра
2) с учетом типа данных

- Что вернет следующая команда?

```
hash_months.values_at "Feb", "apple", "Jan"
#=> ["February", nil, "January"]
```

см. lesson.15/test_values_at

массив значений (nil, если ключа нет) в порядке, соответствующем порядку аргументов при вызове Hash#values_at

- Исследуйте скрипт lesson.15/test_values_at.2

Получение данных из хэша - 2

- Как получить список всех ключей, которые есть в хэше?

  проверьте ваши идеи в irb используя данные из файла loadme

```
load 'loadme'
@months.keys
```

```
Hash#keys
```

- в руби 1.8 порядок элементов в хэше неопределен

  #=> ["Jul", "Apr" , "Jan", "Feb", "Mar", "Jun", "May", ...] ⇦ массив!

- в руби 1.9 – в порядке добавления элементов в хэш

  #=> ["Jan", "Feb", "Mar", "Apr", "May", "Jun", "Jul", ...] ⇦ массив!

Получение данных из хэша - 3

- Вопрос: как получить *все* значения, хранимые в хэше

Hash#values

@months.values

- в руби 1.9

```
#=> ["January", "February", "March", "April", "May", "June", "July"]
```

- Значения в возвращаемом массиве упорядочены по тем же правилам, что и ключи (то есть, нет порядка в 1.8 и в порядке добавления в 1.9)

Значение по умолчанию - 1

- Обращение к несуществующему ключу возвращает nil

```
hash_months ['term']   #=> nil
```

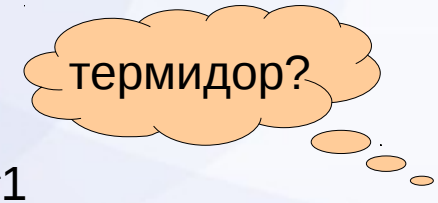

- Проблемная ситуация?

```
counts = {}
counts['apple'] += 1
```

решение #1

```
counts = {}
counts ['apple'] ||= 0
counts ['apple'] += 1
```

- Решение #2 – метод Hash#default=

```
counts = {}
counts.default = 0

counts['apple'] += 1
counts['grapes'] += 1
```

```
ri Hash#default=
ri Hash#default
```

Значение по умолчанию - 2

- Решение #3 – в момент инициализации можно указать значение по умолчанию

```
counts = Hash.new(0)

counts['apple'] += 1
counts['barmeley'] += 1
```

```
ri Hash.new
```

- Что будет напечатано в двух случаях?

```
data = Hash.new("hello")

puts data[9]
data[9].upcase!

puts data['ten']
```

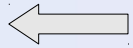

это единственный объект, он присваивается всем новым ключам

#=> "hello"

#=> "HELLO"

Мантра о новом дефолтном объекте

- При обращении к несуществующему ключу, будет создаваться пара

ключ => новый массив

```
hash = Hash.new { |h,k|
   h[k] = []
}
```

многоязычный словарь:

```
words = Hash.new {|h,k| h[k] = []}

words['apple'] << 'Apfel' << 'manzana'
words['butterfly'] << 'Schmetterling' << ...
```

Итерирование по хэшу

- Хэш – **неупорядоченная (?)** коллекция.
  - в руби 1.8 – неупорядоченная
  - в руби 1.9 – упорядоченная в порядке добавления
- Какие есть итераторы в хэшах?

```
Hash#each
Hash#each_pair

Hash#each_key
Hash#each_value
```

возвращает пару ключ-значение

```
hash_months.each do |abbr, full|
   puts "#{abbr} means #{full}"
end
```

- Будет ли это работать? одна переменная вместо двух для ключа и значения?

```
hash_months.each { |a|
    puts a.inspect
}
```

#=> ["Jan", "January"]

Задания

- Есть ли какие-либо отличия в работе между следующими командами?

```
hash_months.each_key do | abbr |
  puts abbr
end
```

```
hash_months.keys.each do | abbr |
  puts abbr
end
```

Задание

- Разработайте скрипт, который находит в списке data/words.txt палиндромы и вольвограммы. Игнорируйте слова длины 1.

палиндром: civic

вольвограмма: stun ↔ nuts

ожидаемый выход: find_palindromes.out (в lesson.15/tasks)

ответ: find_palindromes.rb

- Сделайте вторую реализацию этого скрипта, но с использованием массива вместо хэша.

ответ: find_palindromes_over_array.rb

Сравните время выполнения двух скриптов

```
> time -p  find_palindromes.rb ...
> time -p  find_palindromes_over_array.rb ...
```

Хэши быстрее!

Задание

- Разработайте скрипт, который находит в списке слов data/words.txt анаграммы заданного слова (кроме самого заданного слова).

Слово задается как аргумент при вызове скрипта. Скрипт должен игнорировать различия в регистре (cat и Act нужно считать анаграммами) но выводить слова в первоначальном регистре.

примеры запуска и файлы с ожидаемым выходом:

```
> find_anagrams_of  Reward     # см. find_anagrams_of.Reward
> find_anagrams_of  resist     # см. find_anagrams_of.resist
```

начальный скрипт: find_anagrams_ of_stub (в lesson.15/tasks)

ответ: find_anagrams_of

Домашнее задание

- Разработайте скрипт, который найдет в файле data/words.txt все анаграммы и выведет каждую группу слов в одну строку через табуляцию.

Игнорируйте регистр написания при поиске анаграмм, но выводите слова в исходном регистре

whiter \t wither \t writhe
woodworm \t wormwood

ожидаемый выход: find_all_anagrams.out

ответ: find_all_anagrams

(в lesson.15/tasks)

- Дополнительное задание (по желанию):

сделайте так, чтобы не считались анаграммами такие группы, где *все слова* суть разные регистровые написания одного слова, например:

Workman \t workman

ожидаемый выход: find_all_anagrams.2.out

ответ: find_all_anagrams.2

Массив ARGV

- Массив ARGV содержит все аргументы, с которыми вызывается скрипт, в том же порядке, в каком они указаны в командной строке.

> find_anagrams_of reward filename1 filename2

то массив ARGV содержит следующие **строки**

[“reward”, “filename1”, “filename2”]

- Важно: “reward” не является файлом, поэтому попытка его читать вызовет ошибку

см. lesson.16/test_argv.sh

./test_argv:5:in `gets': No such file or directory - reward (Errno::ENOENT)

ARGV.shift

- Аргументы не-файлы нужно удалить из массива ARGV

```
query = ARGV.shift
```

```
ri Array#shift
```

```
#=> query = “reward”
#=> ARGV = [“filename1”,  “filename2”]
```

- Другие возможности:

```
ARGV.delete_at(0)
```

- Почему не будет работать?

```
ARGV = ARGV[1..-1]
```

```
warning: already initialized constant ARGV
```

это два разных массива ARGV

см. lesson.16/test_argv_2

File.readlines

- Метод класса File.readlines позволяет зачитать весь файл целиком в массив.

```
lines = File.readlines(fname)
```

```
ri File.readlines
```

зачитает с разделителем по умолчанию, то есть \n

- см. lesson.16/test_file_readlines

```
The file shortfile.txt contains the following 4 lines:
["warder is a volvogram\n", "\n", "deified is a palindrom\n", "\n"]
```

- Задание: попробуйте указать в скрипте test_file_readlines в качестве разделителя пустую строку “”

```
File.readlines(fname, “”)
```

```
The file shortfile.txt contains the following 2 lines:
["warder is a volvogram\n\n", "deified is a palindrom\n\n"]
```

Чтение текста блоками

- Разделитель “” позволяет читать файл фрагментами, разделенными как минимум одной пустой строкой.

```
chunks = File.readlines(fname, “”)
```

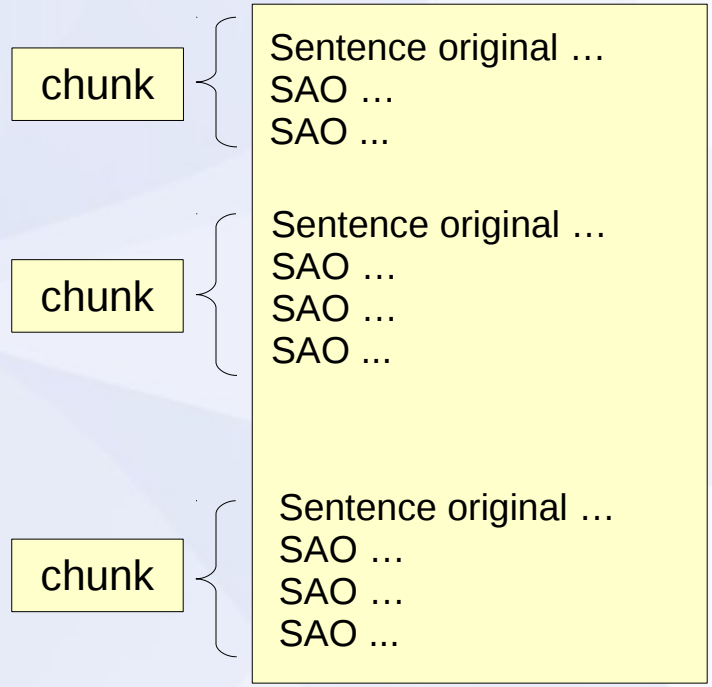

- Это так же справедливо для IO#gets

```
while chunk = gets(“”)
  ...
end
```

- Блок текста *chunk* является одной строкой, с \n внутри

Инициализация Хэша из Массива

- Хэши быстрее массивов => лучше использовать хэши

- Массив массивов вида:

```
[ [k1, v1], [k2, v2], [k3, v3] ... ]
```

можно интерпретировать как массив пар ключ-значение и преобразовать в хэш:

```
keys_and_values = [[1, 'one'], [2, 'two'], [3, 'san']]

h = Hash[ keys_and_values ]
```

ri Hash.[]

```
#=> {1=>"one", 2=>"two", 3=>"san"}
```

см. lesson.16/test_hash_from_array

Преобразование хэша в массив

- “Обратная” операция

```
h = {1=>"one", 2=>"two", 3=>"san"}

h.to_a
```

```
ri Hash#to_a
```

```
#=> [[1, 'one'], [2, 'two'], [3, 'san']]
```

- Преобразование в массив происходит при сортировке хэша

Сортировка хэша

- Hash#sort, Hash#sort_by – работают как в массивах, потому что оба происходят из модуля-примеси Enumerable, общего для Array и Hash

- Эти методы возвращают **массив**, потому что хэш не считается *упорядоченной* структурой данных.

- Выполните скрипт lesson.17/hashsort/test_sort_1.rb

  [["0", "zero"], ["1", "one"], ["10", "ten"], ["11", "eleven"], ["12", "twelve"], ["2", "two"], ...]

  @eng_numerals.sort.class #=> Array

- Вопрос: по какому принципу были упорядочены элементы хэша?

  Ответ: в порядке увеличения (строкового) значения ключей

  “0” < “1” < “10” < “11” < “12” < “2”

Сортировка хэша с блоком

- Метод Hash#sort применяет вот такой блок по умолчанию:

```
hash.sort do |a, b|
    a <=> b
end
```

```
["0", "zero"] <=>  ["10", "ten"]
```

```
hash.to_a.sort do |a, b|
    a <=> b
end
```

```
hash = {
    "0"  => "zero",
    "1"  => "one",
    "2"  => "two"
}
```

- Выполните и проанализируйте скрипт hashsort/test_sort_2.rb

фрагмент вывода:

```
a=["12", "twelve"]
b=["5", "five"]
result of comparison: -1
```

35 сравнений для сортировки 13 элементов

[…, ["12", "twelve"], ["2", "two"], ["3", "three"], ["4", "four"], ["5", "five"], ...]

Задания

- Измените test_sort_2.rb так, чтобы хэш был отсортирован в *нисходящем* порядке по *численному* значению ключа.

  ожидаемый выход:

  [["12", "twelve"], ["11", "eleven"], ["10", "ten"], ["9", "nine"], ["8", "eight"], ["7", "seven"], ["6", "six"], ["5", "five"], ["4", "four"], ["3", "three"], ["2", "two"], ["1", "one"], ["0", "zero"]]

  ответ: hashsort/test_sort_3.rb

- Отсортируйте хэш @numerals (задан в файле data) по испанским числительным в порядке возрастания (в алфавитном порядке).

  ожидаемый выход:

  [["0", ["zero", "cero"]], ["5", ["five", "cinco"]], ["4", ["four", "cuatro"]], ["10", ["ten", "diez"]], ["12", ["twelve", "doce"]], ["2", ["two", "dos"]], ["9", ["nine", "nueve"]], ...]

  ответ: hashsort/test_sort_4.rb

Sort!ировка хэша

- Вопрос: почему нет методов *Hash#sort!* и *Hash#sort_by!* ?

- Ответ: метод Hash#sort меняет сущность объекта: результат сортировки -- объект класса Array, а не Hash.

Сортировка Hash#sort_by

- Метод Hash#sort_by позволяет избавиться от явного сравнения элементов (и оператора <=>).

- Вместо <=>, достаточно сделать так, чтобы блок возвращал то значение, по которому необходимо произвести сортировку.

```
@eng_numerals.sort_by do | key, val |
    key.to_i
end
```

см. hashsort/test_sort_5.rb

```
@eng_numerals = {
  "0"  => "zero",
  "1"  => "one",
  "2"  => "two",
  "3"  => "three",
  "11" => "eleven"
}
```

[["0", "zero"], ["1", "one"], ["2", "two"], ["3", "three"], ["4", "four"], ["5", "five"], ["6", "six"], ["7", "seven"], ["8", "eight"], ["9", "nine"], ["10", "ten"], ["11", "eleven"], ["12", "twelve"]]

- Вопрос: как изменить порядок сортировки на нисходящий?

```
-key.to_i
```

Задание

- Отсортируйте хэш @numerals (задан в файле data) по *обратному* чтению английских числительных (в порядке возрастания). Используйте Hash#sort_by

ожидаемый выход:

[["3", ["three", "tres"]], ["9", ["nine", "nueve"]], ["1", ["one", "uno"]], ["5", ["five", "cinco"]], ["12", ["twelve", "doce"]], ["10", ["ten", "diez"]], ["11", ["eleven", "once"]], ["7", ["seven", "siete"]], ["0", ["zero", "cero"]], ["2", ["two", "dos"]], ["4", ["four", "cuatro"]], ["8", ["eight", "ocho"]], ["6", ["six", "seis"]]]

так как: ee < eni < eno < evi ...

ответ: hashsort/test_sort_ 6.rb

Метод Hash#sort_by_value

- Такого метода нет
- Но его можно реализовать!

```
class Hash
  def sort_by_value
    self.sort_by { |k,v| v }
  end
end
```

- Использование (см. hashsort/test_sort_7.rb):

```
puts @eng_numerals.sort_by_value
```

[["8", "eight"], ["11", "eleven"], ["5", "five"], ["4", "four"], ["9", "nine"], ["1", "one"], ["7", "seven"], ["6", "six"], ["10", "ten"], ["3", "three"], ["12", "twelve"], ["2", "two"], ["0", "zero"]]

Задание cmpsort

Полная формулировка в lesson.17/cmpsort/README

- Необходимо разработать скрипт (cmp_ccs_sort_by_tagseq), который переупорядочивает разницу по CCSplitter-y/MainWordExtractor-y так, чтобы ее было удобно тестировать:
  - CCSplitter опирается на теги входной цепочки => сгруппировать записи разницы по входной цепочке
  - Есть более частотные явления, есть менее частотные. Эту информацию можно учитывать, решая, что тестировать и что нет.

Входной файл:

английский: cmp_ccsplitter_1.out
немецкий: german/cmp_ccsplitter_1.out

Ожидаемый выход в: sorted

Ответ: cmp_ccs_sort_by_tagseq

Задание find_words

полное и пошаговое описание в lesson.16/find_words/README

- Разработать скрипт, который находит в текстовых файлах указанные слова (или фразы) и выводит их в формате

слово \tab позиция_в_предложении \tab предложение

- Если указана опция -i или --ignore-case, то поиск осуществляется без учета регистра и вывод имеет вид:

СЛОВО \tab позиция_в_предложении \tab предложение

- Об опции -t или --output-totals читайте в README

- Файл со словами/фразами для поиска передается как первый аргумент в командной строке. Все остальные аргументы считаются текствыми файлами, в которых происходит поиск.

> find_words queries.txt ../../data/corpus.tok.txt

- Задание необходимо выполнять пошагово, как описано в README

CRF

ВАЖНISSIMO

при назначении properties нельзя опираться на эталонный тег

- тренировка

Эталонный корпус:

слово \t TAG
слово \t TAG

Добавить properties

сл. \t P1 \t TAG
сл. \t P1 \t TAG

synb_crf

модель

config file

- использование

входной файл

слово \t TAG
слово \t TAG

Добавить properties

сл. \t P1 \t TAG
сл. \t P1 \t TAG

synll_crf

CRF добавит вычисленные теги

сл. \t P1 \t TAG \t TAG
сл. \t P1 \t TAG \t TAG

здесь теги не нужны – synll_crf их не использует но умеет их игнорировать

Contest: textspacer/пробелизатор

- Реализовать при помощи CRF и других известных и неизвестных механизмов вставку пробелов в текст на русском языке, из которого были удалены пробелы.

для решения задачи не требуется **полностью токенизировать** текст (т.е. отделять знаки припинания), достаточно получить обычный книжный текст.

все материалы в lesson.22/text_spacer

о работе с UTF-8 см. дальше, в разделе Strings

вместо больших файлов train.txt и test.txt (которые необходимо использовать для тренировки и тестирования рабочей модели CRF) для разработки вспомогательных скриптов нужно использовать файлы train_short.txt и test_short.txt

Изучить test_short.txt и train_short.txt

textspacer: выбор тагсета

- Тагсет должен быть таким, чтобы он позволял выполнить задачу - вставить пробелы. Теги должны сообщать, как вставляется пробел(ы) относительно данного символа.

- Тагсет #1

SL	**s**pace on the **l**eft hand side
SR	**s**pace on the **r**ight hand side
SB	**s**pace on **b**oth sides

- Тагсет #2

SI	**i**nitial symbol
SM	**m**iddle symbol
SL	**l**ast symbol
SW	**s**ymbol is word

- Задание: заполните необходимые секции в конфигурационном файле crf_text_spacer_stub.cfg

описание: http://syn-proc5/wiki/crf/

textspacer: подготовка корпусов - 1

- Требования к формату вытекают из того, что

1. реальные данные приходят в том виде, как дано в **тестировочном** корпусе – исходим из тестировочного корпуса

   i. **минимальной** единицей входа для CRF является **один символ**
   ii. в тексте есть **параграфы** – нужно (?) их сохранить
   iii. *именно для этой задачи, также необходимо сохранить первоначальное количество пустых строк между параграфами*

2. тренировочный и тестировочный корпуса должны быть в одном формате, но надо учесть, что:

   i. если в тестировочном корпусе присутствует эталонный тег, то synll_crf его игнорирует.

   ii. если в тестировочном корпусе тега нет, то строка должна заканчиваться на табуляцию (проверено на данных с одним полем)

textspacer: подготовка корпусов - 2

3. формат, понятный утилитам syn{ll,b}_crf

как в assign_properties

слово \tab тег
слово \tab тег
[между параграфами – одна или более пустых строк]
слово \tab тег
слово \tab тег

i. лишние пустые строки игнорируются

ii. при выводе в synll_crf, между записями вставляется **только одна** пустая строка

противоречие с п. 1-iii

Решение: использовать механизм –skip-line, чтобы протянуть пустые строки через synll_crf

textspacer: подготовка корпусов - 3

- Необходимые действия

	train.txt	test.txt
1. вертикализировать	да	да
2. добавить теги	да	нет (невозможно)
3. удалить пробелы	да	нет/да (пробелов там нет)
4. замаскировать пустые строки	нет/да	да

- Отличия невелики – стоит сделать один скрипт для обоих корпусов
  - Вопрос: стоит ли ввести опцию, для различения видов корпусов или реализовать угадывание в скрипте?

Дихлордиметилтрихлорметилметан! ⟸ Первая строка в корпусе

textspacer: подготовка корпусов - 4

- Задание: реализуйте скрипт verticalize, преобразующий исходные файлы train.txt и test.txt в необходимый формат. Сделайте опцию для добавления тегов. Убедитесь, что работает опция –label-empty-lines.

п4 таблицы (маскировка пустых строк) уже реализована через опцию --label-empty-lines, по которой вместо пустых строк исходного файла вставляется строка #!#EMPTYLINE.

начальный скрипт: verticalize_stub
возможная реализация: verticalize

Ожидаемый выход:

test_short.txt -> test_short.vert
train_short.txt -> train_short.vert

textspacer: конфигурирование CRF

- Сам по себе символ уже является property, и из него можно создать ряд фич
- Общий вид шаблона для **униграмных** фич

UG \tab NAME \tab LINENUM,FIELDNUM *[\tab LINENUM,FIELDNUM]*

где:

LINENUM = 0 указывает на текущую строку
LINENUM > 0 указывает на последующие строки
LINENUM < 0 указывает на предшествующие строки

```
# current character text
UG        CW        0,0
# previous character text
UG        PW        -1,0
# previous character combined with the current character
UG        PCW       -1,0        0,0
```

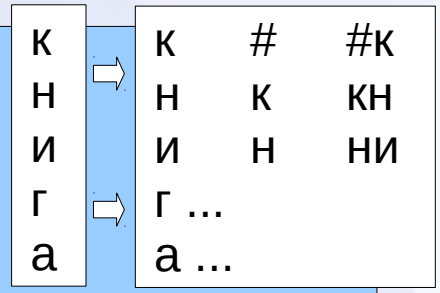

textspacer: конфигурирование

- Задание: добавьте шаблоны для генерации следующих фич
  - current character
  - previous character
  - next character
  - previous character + current character
  - current character + next character
  - previous character + current character + next character

- Вопрос: какие значения должны иметь переменные

STR_WORD_FIELDS_COUNT = 1
INT_WORD_FIELDS_COUNT = 0

Потому что в файле, идущем на вход synb_crf, только одно поле (кроме тега) и оно строковое

- Задание: включите бинарную фичу, которая бы использовались соседние теги.

ответ: crf_text_spacer.crf

textspacer: назначение других properties

- Если нужны дополнительные свойства, то их можно добавить в файл, который идет на вход утилитам CRF

```
слово \tab PROP1 \tab PROP2 \tab тег
слово \tab PROP1 \tab PROP2 \tab тег
```

  - Важно: Количество полей должно во всех строках совпадать!

- При этом в конфигурационном файле необходимо:
  - Изменить значения переменных

```
STR_WORD_FIELDS_COUNT
INT_WORD_FIELDS_COUNT
```

  - Добавить шаблоны для преобразования новых свойств в фичи

- Задание: используйте скрипт **assign_properties**, чтобы добавить как отдельное свойство текст символа в нижнем регистре.

см. дальше, как работать с регистром в UTF-8

textspacer: тренировка модели

- Исходник корпуса (статичен)
- Обогащен доп. свойствами (изменяется)

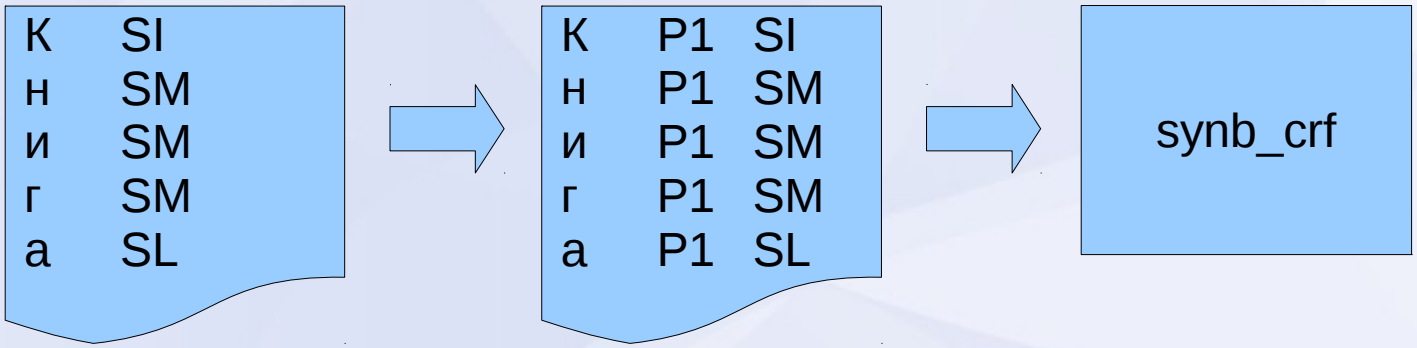

- Как запускать:

train_crf

```
cat train.vert |
assign_properties |
synb_crf --bin=model.bin --min-feat=2 --config=crf_text_spacer.cfg
```

- Пример промежуточной информации, выводимой synb_crf: *synb_crf.log*

  Exit code of training procedure: 1 – это хорошо

textspacer: keep your stuff under control

- Используйте git для хранения версий нужных файлов: *assign_properties*, *crf_text_spacer.cfg*
  - чтобы создать репозиторий в текущей директории

```
git init .
```

  - чтобы добавить к проекту файлы

```
git add file1 file2...
```

  - чтобы закомитить в *локальный* репозиторий

```
git commit -m “message”
```

  - пушить в *удаленный* репозиторий не надо (его нет, но можно настроить удаленный репозиторий)

textspacer: применение в боевых условиях

- Чтобы использовать модель для теггирования:

```
cat train.vert | assign_properties | synll_crf –bin=model.bin --stat
```

Файл train.vert содержит эталонные теги, опция *–stat* позволяет получить цифры по качеству работы теггера, сравнивая эталонные и вычисленные теги.

- Опция *–skip-line=XXX* позволяет пропустить через утилиту некоторую строку и получить ее в неизмененном виде в выдаче.

По условию соревнования в выдаче необходимо сохранить пустые строки между параграфами, которые были замаскированы при помощи метки #!#EMPTYLINE.

```
cat test.vert | assign_properties |
synll_crf –bin=model.bin –skip-line='#!#EMPTYLINE'
```

textspacer: вставка пробелов

- Задание: разработайте скрипт, вставляющий пробелы в текст согласно тегам, вычисленным моделью.

Скрипт должен уметь принимать данные с любым количеством полей:

restore_spaces.1.in
restore_spaces.2.in

Ожидаемых выход для обоих входных файлов одинаковый:

restore_spaces.all.out

Скрипт должен распознавать метку *#!#EMPTYLINE* и вставлять вместо нее пустую строку. Эта логика уже реализована.

Начальный скрипт: restore_spaces_stub
Возможная реализация: restore_spaces

Congratulations! You have completed the quest.
Now you can submit the test.txt file with restored spaces to the contest by copying it into predefined directory.

String

строковый класс

Charset

- Вначале было Слово и было оно класса String.
- Но еще раньше были числа.
- Любому символу из кодовой страницы соответствует число, в однобайтной кодировке это число в диапазоне 0..255

http://en.wikipedia.org/wiki/Windows-1251	кириллическая
http://en.wikipedia.org/wiki/Windows-1252	латинская

- Символы с кодами 0..127 одинаковые. Это 7-битное ASCII
- Верхняя часть таблицы - языкозависимая.

код 196	Windows-1251	Д
	Windows-1252	Ä

Порядок символов и локаль

- Локаль влияет на порядок сортировки символов

unsorted	C	ru_RU.UTF8
A	A	a
b	B	A
B	a	á
a	b	b
Ö	Ö	B
á	á	Ö

файл: lesson.21/chars.txt

- Give it a try

```
> cat chars.txt | LC_ALL=C sort
> cat chars.txt | sort
```

- Сортировка согласно локали C располагает символы в том порядке, в каком они расположены в кодовой таблице, то есть, в порядке возрастания их кодов.

- Сортировка согласно др. локалей опирается на другой порядок расположения символов.

Символ <--> Код

- Преобразование символа в код и наоборот.

String#ord

```
“A”.ord   #=> 65
“a”.ord   #=> 97
```

Integer#chr

```
65.chr    #=> “A”
97.chr    #=> “a”
```

- Вопрос: какой код имеют символы пробел, табуляция, \n, \r и пустая строка?

```
“ ”.ord       #=> 32
“\t”.ord      #=> 9
“\n”.ord      #=> 10
“\r”.ord      #=> 13
“”.ord
```

пустая строка
не является символом

- Вопрос: какой код имеет символ Ö и в какой кодировке его видит Руби?

```
“Ö”.ord #=> 214, как в windows-1252
“Ö”.encoding #=> #<Encoding:UTF-8>
```

ri String#encoding

UTF-8

- Однобайтные vs. многобайтные кодировки
  - однобайтные кодировки: 1 байт = 1 символ

  - Многобайтные кодировки: 1+ байт (октетов) = 1 символ

- Исследуйте, как работает скрипт lesson.22/unicode/test_russian_utf8 без установленной внешней кодировки и с ней

```
Encoding::default_external = 'UTF-8'
```

Разное разбиение,
разная длина символов

```
> test_russian_utf8 test_russian_utf8.txt
```

Преобразование регистра в UTF-8

- Исследуйте скрипт unicode/test_russian_utf8_2 с @use_mb_chars=true|false

  > test_russian_utf8_2 test_russian_utf8.txt

  - Регистр не преобразуется!

- Регистровые преобразования не поддерживаются в ядре языка

  - потому что регистровые преобразования зависят от локали

    В турецком: ı <=> I
    i с точкой и без i <=> İ

    dotted/undotted i
    http://en.wikipedia.org/wiki/Turkish_alphabet

  - некоторые преобразования не биективны (не взаимно-однозначны)

    в немецком: ß => SS, но не всякое SS => ß

  - может быть, есть языки, в которых прописные выглядят как строчные. То есть, нельзя однозначно приписать символу свойство lowercase или uppercase

Преобразование регистра: решение

- Использовать библиотеки
  - механизм Multibyte из ActiveSupport

```
shell> gem install active_support i18n
```

установка

```
require 'active_support/lazy_load_hooks'
require 'active_support/core_ext/string'

'ящерица'.mb_chars.upcase.to_s
```

```
# may not be necessary

#=> "ЯЩЕРИЦА"
```

  - gem (пакет) unicode_utils (http://unicode-utils.rubyforge.org/)

```
shell> gem install unicode_utils
```

```
require 'unicode_utils'

UnicodeUtils.upcase('ящерица')
```

```
#=> "ЯЩЕРИЦ"
```

Установка гемов простыми смертными

- По умолчанию пакетный менеджер gem устанавливает пакеты в системные директории (/usr/)
  - в линуксе это может сделать только суперпользователь
- Чтобы установить в HOME:

```
> gem1.9.1 install --user-install active_support i18n
```

- настроить окружение (.bashrc) и перестартовать терминал

~/.bashrc

```
if which ruby >/dev/null && which gem >/dev/null; then
    PATH="$(ruby -rubygems -e 'puts Gem.user_dir')/bin:$PATH"
fi
```

  - эта команда добавляет в переменную PATH новый путь

```
>echo $(ruby -rubygems -e 'puts Gem.user_dir'
  #=> /home/krot/.gem/ruby/1.9.1
```

Неожиданный String#[]

см. lesson.22/test_getting_chars

Заголовок